

Adéquation formation-emploi au Togo

Comment ce tableau de bord a été construit — énoncé, postulats, méthodes

256 établissements techniques · 9 ressources ouvertes · 14 indicateurs du cahier des charges passés en revue

Kokou PIPi · Data AI Lab · Data Challenge Éducation, défi 2

2 · L'énoncé

Ce que le défi demandait, et ce que j'en ai fait une question mesurable

- **La question posée** « L'offre de formation est-elle alignée sur les besoins de l'économie togolaise ? »
- **Six objectifs** cartographier l'offre, mesurer l'accès, suivre les moyens publics, décrire l'insertion, croiser, recommander
- **Un corpus imposé** les ressources ouvertes du portail national, et elles seules

La reformulation

Une question d'opinion peut-elle se mesurer ?

Oui, en trois écarts

« Alignement » ne se mesure pas directement. Je l'ai éclaté en trois écarts observables : entre les territoires, entre l'accès et les moyens, entre la formation et l'insertion. Chacun se calcule ; leur somme ne se calcule pas, et je ne l'ai pas inventée.

3 · Les attendus

Quatorze indicateurs, quatre livrables — et un verdict public pour chacun

Indicateurs honorés

9

calculés et affichés

Partiellement

2

la donnée existe, mais pas à la maille demandée

Impossibles

3

et la planche dit POURQUOI

- **Les quatre livrables** un tableau de bord bilingue, un rapport de dix pages, l'archive du code et des données, un diagnostic d'installation
- **Le principe** un indicateur impossible reste AFFICHÉ, avec sa cause — le masquer donnerait l'illusion d'un travail complet

4 • Le matériau

Neuf ressources — et une asymétrie qui commande tout le reste

- **8 ressources chargées** sur 9 ; la neuvième est une table de contrôle du jeu technique
- **1 seule descend sous le national** les 256 établissements techniques, géolocalisés
- **7 séries nationales** budget, inscriptions, dépense, chômage, effectifs — un seul chiffre par année
- **Périodes hétérogènes** supérieur 2018, technique 2025, séries internationales 1971-2022

La conséquence

Pourquoi cette asymétrie décide de tout ?

Aucun score régional composite

Un indicateur national ne peut pas entrer dans un classement de régions : il y apporterait la même valeur partout, en donnant l'illusion d'avoir été mesuré localement. Le chômage des diplômés est donc absent de tous les scores territoriaux, et la vue le dit.

5 · Les postulats

Quatre règles posées AVANT de regarder les données — donc avant de savoir ce qu'elles arrangeraient

1 · Aucune donnée fabriquée

Que faire d'une série trouée ?

On laisse le trou

Ni interpolation, ni moyenne de remplissage. Les non-réponses restent visibles sous « Non renseigné » : les supprimer embellirait toutes les répartitions.

2 · Aucun croisement non autorisé

Peut-on croiser deux mailles différentes ?

Non, jamais en silence

Chaque croisement déclare ses ingrédients, sa clé de jointure et son nombre d'observations. Cinq années communes n'autorisent pas les conclusions de dix.

3 · Le non-significatif s'affiche

Que fait-on d'un modèle qui ne conclut pas ?

On le publie quand même

Deux des cinq modèles ne concluent pas. Les retirer donnerait à l'ensemble une solidité qu'il n'a pas.

4 · Le contexte externe reste dehors

Peut-on compléter avec d'autres sources ?

Oui, mais séparément

Les repères d'enquêtes nationales sont sourcés, signalés visuellement, et n'entrent dans aucun calcul du corpus.

6 · Méthode, temps 1 — identifier les données

Avant tout calcul : ouvrir chaque fichier, le compter, et décider ce qu'il a le droit de dire

- **Ouvrir, pas supposer** chaque fichier est lu ligne à ligne : combien d'observations, quelles colonnes, quelles valeurs manquantes
- **Situer sa maille** national, régional, ponctuel — c'est elle qui décide des croisements possibles
- **Situer sa période** 1971-2022 pour les séries, 2018 pour le supérieur, 2025 pour le technique
- **Comparer au dictionnaire** le fichier tient-il ce que ses métadonnées annoncent ?

Champs publiés, sur ceux décrits

16 / 216

201 champs collectés ne sont pas diffusés

Ce que cette étape a trouvé

Un fichier peut-il se contredire ?

Oui — et il fallait trancher

Le fichier du supérieur inscrit 14 établissements privés sur sa ligne de total, quand le détail par ville en compte 65. J'ai retenu le détail : c'est un CHOIX, il est écrit dans les annexes, et tous les chiffres du supérieur en dépendent.

7 · Méthode, temps 2 — croiser les données

Six croisements, chacun déclarant sa clé, ses ingrédients et son nombre d'observations

- **Accès × moyens** inscriptions au supérieur contre dépense par étudiant
- **Budget × accès** l'enveloppe votée suit-elle le nombre d'étudiants ?
- **Cohérence du financement** budget exécuté contre dépense par étudiant
- **Réseaux par région** technique et supérieur sur le même territoire
- **Accès × insertion** inscriptions contre chômage des diplômés
- **Accès × effectifs** féminisation et filières scientifiques

La règle du croisement

Qu'est-ce qui rend une jointure honnête ?

Dire sur combien elle porte

Chaque croisement affiche ses deux fichiers, sa clé — presque toujours l'année — et le nombre d'observations qui survivent à la jointure. Deux séries qui se recouvrent sur cinq ans n'autorisent pas les conclusions de vingt, et le lecteur doit voir ce nombre avant de lire le résultat.

8 · Méthode, temps 3 — les outils, et ce qu'ils font

Trois outils pour mesurer une relation entre deux séries

La régression linéaire

Que fait-elle, concrètement ?

Elle trace la droite la plus proche des points

Sa pente dit : « quand x augmente d'une unité, y bouge de tant ». Je ne publie jamais la pente seule, mais avec trois garde-fous — le R^2 , part de la variation expliquée ; la p-value, probabilité que le hasard suffise ; l'intervalle de confiance, la fourchette où se trouve la vraie pente.

La tendance temporelle

Et quand x est le temps ?

Elle donne un rythme : tant par an

C'est la même régression, avec les années en abscisse. Elle répond à « de combien cela bouge-t-il chaque année », ce qui se dit et se retient mieux qu'un coefficient abstrait.

L'élasticité

Comment comparer des grandeurs sans unité commune ?

En passant les deux au logarithme

La pente devient alors un pourcentage : ici, quand l'accès augmente de 1 %, la dépense par étudiant recule de 0,86 %. Un nombre d'étudiants et un pourcentage de PIB deviennent comparables.

9 · Méthode, temps 3 — les outils (suite)

Un outil pour la forme d'une relation, deux pour une répartition

La corrélation, mesurée deux fois

Pourquoi Pearson ET Spearman ?

Ils ne demandent pas la même chose

Pearson demande si les points s'alignent sur une droite. Spearman demande seulement s'ils montent et descendent ensemble. Quand les deux s'écartent, la relation existe mais n'est pas linéaire — et cet écart est une information, pas un défaut.

Les deux indices de concentration

Comment chiffrer un déséquilibre territorial ?

Herfindahl et Gini, ensemble

Herfindahl additionne les carrés des parts : il s'envole dès qu'un acteur domine. Gini décrit toute la distribution : zéro si tout le monde a la même chose, un si tout est chez un seul. Ici 0,41 et 0,48.

Le test de rupture

Une tendance peut-elle changer en cours de route ?

On coupe la série et on compare

On calcule la pente avant une année charnière, puis après. Sur l'accès au supérieur, la rupture est en 2000 : 0,09 point par an avant, 0,63 après. La progression a changé de régime, elle n'a pas seulement continué.

Exécution contre enveloppe

Les grosses enveloppes se dépensent-elles moins bien ?

Question posée, réponse non concluante

Une régression du taux d'exécution sur le montant voté. La pente va dans le sens attendu, mais l'intervalle de confiance traverse zéro : sur six années, on ne peut pas conclure — et c'est publié ainsi.

10 · Ce que la méthode produit

Trois résultats, chacun rattaché à l'outil qui l'établit

des établissements dans une région

60 %

Herfindahl 0,41 · Gini 0,48

Accès et dépense, base 100 en 1998

×4,7 / ÷3,6

accès jusqu'en 2020, dépense jusqu'en 2017 — le calcul de l'élasticité, lui, ne porte que sur leurs 10 années communes

Exécution du budget supérieur

93 %

contre 76 % au niveau national

Le résultat le plus solide

log(dépense/étudiant) contre log(accès), 10 années

Élasticité -0,86

R² de 0,83, p-value sous 0,001, intervalle de confiance entièrement négatif. Quand l'accès augmente de 1 %, la dépense par étudiant recule de 0,86 %.

Le résultat qui NE conclut pas

taux d'exécution contre montant voté, 6 années

p = 0,12

La pente est négative et le R² correct, mais l'intervalle de confiance traverse zéro : sur six années, on ne peut pas conclure. C'est publié tel quel.

11 · Ce que la méthode refuse d'établir

Trois manques, trois causes différentes — et trois remèdes différents

Collecté, non publié

Combien d'élèves par établissement ?

201 champs manquants

Le remède est une EXPORTATION : la donnée existe, elle est déjà collectée. Aucune enquête à financer.

Inexistant à la maille utile

Quel taux d'insertion par filière ?

Le chômage n'existe qu'au national

Le remède est une ENQUÊTE d'insertion. Trois croisements attendus par l'énoncé restent hors de portée.

Nomenclature absente

Quelle part de filières scientifiques ?

Aucun référentiel de métiers

Le remède est un RÉFÉRENTIEL national. Sans lui, le dénominateur n'existe pas.

- **Un indicateur absent** signifie toujours ABSENT DU CORPUS RETENU, jamais inexistant — la nuance change la recommandation

12 · Comment tout cela se vérifie

Le travail est fait pour être contredit — encore faut-il pouvoir le refaire

- **Un chiffre, une source** les commentaires sous les graphes se recalculent sur la sélection : aucun nombre n'est figé dans un texte
- **Le rapport ne peut pas diverger de l'écran** il est produit par les mêmes fonctions, à partir des mêmes données, en une seule collecte
- **L'archive contient les données brutes** telles que téléchargées du portail, non modifiées
- **Un diagnostic livré** une commande contrôle la version de Python, les bibliothèques et les fichiers avant tout lancement
- **Le tableau de bord est en ligne** tg-datalab-education-challenge2.bernardpip.com — rien à installer pour le juger

13 • Des constats aux recommandations

26 leviers, 5 axes — chacun part d'un chiffre, aucun d'une opinion

Leviers d'action

26

chacun renvoie à la vue qui l'établit

Première décision recommandée

1

elle est informationnelle, pas budgétaire

La règle de rédaction

Qu'est-ce qui distingue un levier d'un vœu ?

Un constat chiffré, et une vue qui le porte

Chaque levier commence par le chiffre qui le motive et renvoie à l'onglet où ce chiffre se vérifie. Aucun n'est une recommandation générique du type « renforcer la coordination ». Et la toute première n'est pas de dépenser : c'est de publier les 201 champs déjà collectés — parce que sans eux, on pilote à l'aveugle.

14 · Ce qui est réutilisable

La méthode a été rejouée sur un second défi, en quelques jours

- **Un socle partagé** coquille, charte, graphes, cartes, i18n, économétrie — le défi n'écrit que ses analyses
- **Les mêmes règles de rigueur** aucune donnée fabriquée, aucun croisement non autorisé, le non-significatif affiché
- **La même chaîne de livraison** tableau de bord bilingue, rapport, archive restructurable, diagnostic
- **Preuve par l'usage** le défi Environnement — eau et hydraulique — a été construit sur ce socle, avec ses propres analyses

15 • Conclusion

Ce que ce travail établit, et ce qu'il laisse ouvert

Ce qui est établi

L'alignement est-il réalisé ?

Non, sur les trois écarts mesurés

L'offre est concentrée sur un territoire, l'accès progresse quand les moyens par étudiant reculent, et l'insertion ne peut pas être suivie faute de donnée locale. Les deux premiers écarts sont mesurés ; le troisième est un manque, et c'en est un résultat.

Ce qui reste ouvert

Que faudrait-il pour aller plus loin ?

Trois gestes, dans cet ordre

Publier les 201 champs collectés. Lancer une enquête d'insertion ventilée par filière et par région. Établir un référentiel national des métiers. Aucun des trois n'est un travail de statisticien : ce sont des décisions.

- **La phrase que je retiens** un tableau de bord honnête montre d'abord ce qu'il ne peut pas montrer — c'est à cela qu'on voit qu'il n'a rien inventé